

적대적 생성 신경망의 생성 이미지 다양성 개선을 위한 지각적 코사인 유사도 손실함수 기반의 모델 학습방법

서상원¹ · 박현철^{2*}

A Training Method for Improving Image Diversity in Generative Adversarial Networks Using a Perceptual Cosine Similarity Loss

Sang-Won Seo¹ · Hyun-Cheol Park^{2*}

¹Undergraduate Student, Department of Computer Engineering, Korea National University of Transportation,
Chungju-si, 27469 Korea

^{2*}Assistant Professor, Department of Computer Engineering, Korea National University of Transportation,
Chungju-si, 27469 Korea

요 약

적대적 생성 신경망은 고품질 이미지 생성에서 뛰어난 성능을 보이지만, 제한된 유형의 샘플만을 생성하는 모드 붕괴 문제를 겪는다. 본 연구에서는 네트워크 구조를 변경하지 않고도 적용 가능한 코사인 유사도 기반의 다양성 손실 함수를 제안한다. 제안된 손실 함수는 생성된 이미지로부터 추출한 특징 벡터 간의 코사인 유사도를 최소화함으로써 중복 생성을 억제하고 잠재 공간의 의미적 연속성을 유지한다. 본 방법은 LSUN Bedroom 및 CelebA 데이터셋을 대상으로 DCGAN 구조에 적용하여 평가한다, FID 및 LPIPS 지표를 활용한 실험 결과, 네트워크 구조의 수정 없이도 간단한 손실 항 추가만으로 이미지의 품질과 다양성을 효과적으로 개선할 수 있음을 확인한다.

ABSTRACT

Generative Adversarial Networks (GANs) demonstrate strong performance in high-quality image synthesis but still suffer from mode collapse, where only a limited range of samples is generated. This study proposes a diversity loss based on cosine similarity that can be applied without modifying the network architecture. The proposed loss reduces redundant generation by minimizing the cosine similarity between feature vectors extracted from generated images, thereby enhancing diversity. This method allows for the preservation of semantic continuity in the latent space while encouraging the generation of more varied outputs. The effectiveness of the proposed loss is evaluated on the LSUN Bedroom and CelebA datasets using the DCGAN architecture. Experimental results based on FID and LPIPS metrics confirm that our method can effectively improve both the diversity and quality of generated images. Notably, these improvements are achieved without any changes to the network architecture, relying solely on the addition of a simple loss term during training.

키워드 : 적대적 생성 신경망, 모드 충돌, 잠재 공간의 연속성, 다양성 손실

Keywords : Generative Adversarial Network(GAN), Mode collapse, Latent Space Continuity, Diversity Loss

Received 12 August 2025, Revised 1 September 2025, Accepted 23 September 2025

* Corresponding Author Hyun-Cheol Park(E-mail:hc.park@ut.ac.kr),

Assistant Professor, Department of Computer Engineering, Korea National University of Transportation, Chungju-si, 27469 Korea

Open Access <http://doi.org/10.6109/jkiice.2025.29.10.1357>

pISSN:2234-4772

© This is an Open Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License(<http://creativecommons.org/licenses/by-nc/3.0/>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.
Copyright © The Korea Institute of Information and Communication Engineering.

I. 서 론

적대적 생성 신경망은 높은 품질의 이미지를 생성할 수 있는 대표적인 생성 모델로, 이미지 생성, 얼굴 합성, 스타일 변환 등 다양한 컴퓨터 비전 분야에서 널리 활용되고 있다[1]. 그러나 적대적 생성 신경망은 학습의 불안정성과 함께 제한된 유형의 이미지만을 생성하는 모드 붕괴 문제를 겪으며, 이는 생성 모델의 실용성과 확장성에 큰 제약이 된다[2,14].

이러한 문제를 해결하기 위해 다양한 접근 방식이 제안되어 왔다. 낮은 해상도에서 시작하여 점진적으로 고해상도로 키워나가면서 훈련을 안정화하고 고품질 이미지 생성을 가능 시킨 점진적 성장 기법[3], 컨볼루션 연산의 국소성 한계를 극복하고, 이미지 생성 및 판별 과정에서 전역적이고 장거리적인 맥락 정보를 효율적으로 활용함으로써 이미지 품질과 다양성을 크게 향상시킨 자가 주의 메커니즘[4], 실제 및 생성된 이미지에 동일한 미분 가능한 변환을 적용하여 판별자의 데이터 압기를 막고, 생성자에게 유의미한 기술기를 제공함으로써 적대적 생성 신경망의 학습 안정성 및 데이터 효율성을 크게 개선한 DiffAugment 기법[5], 학습 불안정성을 해결하기 위해 판별자 네트워크에 스펙트럴 정규화를 적용하는 기법[6] 등이 있다. 이들 방법은 성능 향상에 효과적이지만, 대부분 모델 구조에 대한 복잡한 수정 또는 추가 모듈의 도입을 요구하며, 이로 인해 구현의 복잡성과 계산 자원의 부담이 증가한다는 한계를 가진다. 이러한 접근은 여전히 모드 붕괴 문제에 취약하며, 최근에는 분포 제약 기반의 모드 붕괴 완화 기법[17], 판별기 임베딩 공간에서의 엔트로피 최대화 방법[18], 동적 클러스터링을 활용하는 DynGAN 기법[19], 그리고 HingeRLC-GAN과 같이 힌지 손실과 정규화를 결합한 최신 방식이 제안되고 있다[20]. 또한 RIS-GAN[21], Augmentation-Aware Self-Supervision [22], Blend-Ratio Self-Supervision[23]과 같은 자기지도 학습 기반의 데이터 효율적 GAN 훈련 기법도 활발히 연구되고 있다.

기존 연구의 많은 수가 실험적 경험이나 트릭에 기반하여 발전해 온 반면, 본 연구는 네트워크 구조를 변경하지 않고도 이론적으로 타당한 방식으로 이미지 다양성을 향상시킬 수 있는 손실 함수 설계를 목표로 한다. 우리는 DCGAN[7] 구조를 유지한 상태에서, 생성 이미

지 간 표현 중복을 억제하는 코사인 유사도 기반 다양성 손실 함수를 제안한다. 이 손실 항은 생성 이미지에서 추출한 특징 벡터 간의 코사인 유사도를 최소화함으로써 다양한 출력 분포를 유도하며, 잠재 공간의 의미적 연속성은 보존된다.

고수준의 시각적 표현을 효과적으로 포착하기 위해, 생성 이미지의 특징 추출에는 사전 학습된 VGG16네트워크를 사용한다[10]. 해당 네트워크는 이미지 간의 시각적 유사도를 정량화하는 데 적합한 특징을 제공한다[15].

본 논문은 수학적 근거와 통계적 분석을 바탕으로 제안한 손실 함수의 정당성을 입증하고, LSUN Bedroom[11] 및 CelebA[12] 데이터셋에 대해 DCGAN[7]에 적용한 실험을 통해 FID[8]와 LPIPS[9] 지표에서 명확한 개선을 확인한다.

II. 본 론

2.1 다양성 손실 함수

제안된 다양성 손실 함수는 생성된 이미지 간의 고수준 표현의 유사도를 기반으로 한다. 먼저 생성된 이미지들을 사전 학습된 VGG16네트워크에 통과시켜 특징 맵을 추출한다[10]. 이 특징 맵은 시각적으로 의미 있는 고수준 정보를 포함하고 있으며, 이를 다양성 손실을 통해 이미지 간 표현의 중복을 정량화할 수 있다.

추출된 특징 맵은 1차원 벡터로 변환된 후, L2 정규화를 통해 단위 벡터로 정규화된다. 이후 배치 내 모든 쌍에 대해 코사인 유사도를 계산하며, 이들의 평균값을 다양성 손실로 사용한다. 수식은 다음과 같다:

$$L_{div} = \frac{2}{N(N-1)} \sum_{i < j} f_i \cdot f_j \quad (1)$$

여기서 N 은 미니 배치의 크기이고, f_i 와 f_j 는 배치 내 생성된 이미지들의 정규화된 특징 벡터이다.




Fig. 1 Gradient Effect of Diversity Loss

그림. 1은 다양성 손실 함수 L_{div} 가 작용하는 과정을 시각적으로 나타낸 것이다. 네트워크는 L_{div} 를 최소화하는 방향으로 파라미터를 조정하게 되며, 이로 인해 초기에는 두 벡터 사이의 각도가 θ_1 로 작지만, 학습이 진행됨에 따라 θ_2 로 증가하게 된다.

이는 다양성 손실이 서로 유사한 출력을 억제하고, 서로 다른 잠재 벡터에서 보다 다양한 이미지를 생성하도록 유도하는 역할을 함을 의미한다. 다시 말해, 코사인 유사도를 최소화하는 손실 구조를 통해 생성 이미지 간 표현 공간의 분산을 증가시키고, 결과적으로 모드 붕괴를 완화하며 전체적인 표현 다양성을 향상시킨다.

2.2 고정된 가중치와 잠재 공간의 연속성

제안하는 다양성 손실 항은 생성된 이미지 간 표현의 중복을 줄이고 다양성을 높이기 위한 목적을 갖지만, 동시에 잠재 공간의 연속성을 해치지 않도록 주의 깊게 설계되어야 한다[16]. 만약 잠재 벡터 간의 거리가 매우 가까움에도 불구하고 동일한 강도의 다양성 손실이 적용된다면[13], 근접한 벡터가 생성하는 이미지 간의 변화가 과도하게 커질 수 있어, 잠재 공간의 연속적 구조를 위협할 수 있다.

이를 정량적으로 이해하기 위해, 차원 $d=100$ 인 잠재 공간 상에서 표준 정규분포 $N(0, I)$ 로부터 두 벡터 $z_1, z_2 \in R^{100}$ 를 독립적으로 샘플링한다고 가정한다. 이때 이들 사이의 거리의 제곱은 다음과 같이 표현된다:

$$\|z_1 - z_2\|_2^2 = \sum_{i=1}^{100} (z_{1,i} - z_{2,i})^2 \quad (2)$$

각 성분 $z_{1,i} - z_{2,i}$ 는 평균 0, 분산 2인 정규분포

$N(0, 2)$ 를 따른다, 이에 따라 $\|z_1 - z_2\|_2^2 \sim 2 \cdot \chi^2(100)$ 가 성립한다. 거리의 기댓값 $E[\|z_1 - z_2\|_2]$ 은 카이제곱 분포의 제곱근인 카이 분포의 성질을 따르고, 감마 함수 비율로 표현되며 다음과 같이 유도된다:

$$E_{X \sim \chi(d)}[X] = \sqrt{2} \cdot \frac{\Gamma((d+1)/2)}{\Gamma(d/2)} \quad (3)$$

$$E[\|z_1 - z_2\|_2] = \sqrt{2} \cdot E[X] = 2 \cdot \frac{\Gamma(50.5)}{\Gamma(50)} \approx 14$$

이는 실제로 표준 정규분포에서 샘플링된 두 잠재 벡터 간의 평균 거리가 약 14에 수렴함을 의미한다. 이러한 통계적 성질로 인해, 학습 시 무작위로 샘플링된 잠재 벡터 쌍 중 근접한 쌍의 비중은 매우 작으며, 고정된 가중치를 적용하더라도 연속성을 해칠 가능성은 낮다. 본 연구에서는 이러한 이론적 근거와 함께 실험을 통해 고정된 가중치 기반의 다양성 손실이 연속성을 유지하면서도 다양성을 향상시킴을 확인한다.

2.3 최종 손실 함수 구성

샘플링된 잠재 벡터 간 평균 거리가 잠재 공간의 연속성에 영향을 미치지 않는다고 가정하며, 본 연구는 고정된 가중치를 통해 다양성 손실을 생성자 학습에 통합한다. 이에 따른 생성자의 최종 손실 함수는 다음과 같다:

$$L_G = L_{adv} + \lambda_{div} \cdot L_{div} \quad (4)$$

여기서 L_{adv} 는 기존 적대적 생성 신경망의 적대적 손실이고, L_{div} 생성 이미지 간 표현 유사도를 최소화하는 다양성 손실, λ_{div} 고정된 가중치이다.

III. 실험

3.1 실험 설정

본 연구에서는 제안하는 다양성 손실 항의 효과를 검증하기 위해, DCGAN 구조를 유지한 채 실험을 진행한 다[7]. 실험에 사용된 데이터셋은 CelebA[12] 및 LSUN Bedroom[11]으로, 모두 해상도 64×64 로 변환하여 사용한다.

생성자는 적대적 손실과 제안하는 다양성 손실 항을

동시에 최소화하도록 학습되며 다양성 손실 항의 가중치 λ_{div} 는 1.0으로 고정하여 실험을 수행한다. 판별자는 적대적 손실만을 최소화한다.

모든 실험은 동일한 학습 조건에서 수행된다. 옵티마이는 Adam을 사용하며, 학습률은 생성자와 판별자 모두 0.0002로 고정한다. β_1 과 β_2 는 각각 0.5와 0.999로 설정한다. 배치 크기는 128로 고정한다. VGG16의 앞쪽 16개 계층을 사용한다[10].

생성 이미지의 품질은 FID지표를 통해 측정했으며[8], 이미지의 다양성은 LPIPS지표를 활용하여 정량적으로 평가한다[9]. 50,000장의 학습 이미지와 50,000장의 생성 이미지를 생성하여 FID[8]를 측정했으며, LPIPS[9]는 잠재 벡터 간의 거리[13]를 고정한 후 이미지를 생성하여 계산한다.

3.2 정량적 평가 및 생성된 이미지

고정된 가중치로 학습하더라도 잠재 공간의 연속성이 유지됨을 2.2절에서 수학적으로 보인 바 있다. 본 절에서는 잠재 벡터 간 거리 $D(z_1, z_2)$ 가 각각 0.1, 10.0, 14.0인 경우에 대해 생성된 이미지 쌍의 LPIPS 값을 측정한다[9]. 이를 통해 제안한 손실 항이 잠재 공간의 연속성을 유지하면서도 다양한 이미지를 효과적으로 생성함을 실험적으로 검증하고자 한다.

Table. 1 LSUN Bedroom[11]

	DCGAN [7]	Ours
FID	61.8187	55.4697
LPIPS (D = 0.1)	0.0007	0.0007
LPIPS (D = 14)	0.3444	0.3529

Table. 2 CelebA[12]

	DCGAN [7]	Ours
FID	39.4036	26.2780
LPIPS (D = 0.1)	0.0002	0.0002
LPIPS (D = 10)	0.1734	0.1816

LSUN Bedroom[11]과 CelebA[12] 데이터셋 모두에서, 제안하는 모델은 FID[8]와 LPIPS[9]측면에서 기존 DCGAN[7]대비 향상된 성능을 보인다. 이는 제안된 모델이 이미지의 품질을 희생하면서 다양성을 증가시키는 것이 아니라, 품질과 다양성 두 가지 목표를 동시에

달성하고 있음을 의미한다. 이러한 결과는 수학적으로 정교하게 설계된 손실 항만으로도 별도의 경험적 트릭 없이 적대적 생성 신경망의 품질과 다양성을 효과적으로 개선할 수 있음을 시사한다.

또한, 고정된 가중치로 학습하더라도 $D(z_1, z_2) = 0.1$ 인 경우 DCGAN[7]과 제안 모델의 LPIPS[9]수치가 동일하게 유지되었는데, 이는 고정된 가중치 설정만으로도 잠재 공간의 연속성이 유지됨을 보여준다[16]. 나아가 거리 기반 가중치를 적용한 학습에서도 고정 가중치와 같은 정량적 결과가 나타나는데, 이는 학습 중 샘플링된 잠재 벡터 간의 평균 거리는 약 14 ($d = 100$)에 수렴하며, 이는 $D(z_1, z_2) = 0.1$ 을 140배 벗어난 거리이다. 따라서, 다양성 손실이 가까운 벡터 쌍에 대해 상이한 이미지를 생성하도록 유도하더라도, 대부분의 잠재 벡터 쌍은 이 영향에서 벗어나게 된다. 이는 앞서 2.2절에서 제시한 수학적 분석과 일치하며, 고정된 가중치 하에서도 잠재 공간의 연속성이 유지된다는 점을 실험적으로도 뒷받침한다.



Fig. 2 Sample images generated by the DCGAN[7] model trained on the CelebA[12] dataset. The FID[8] score is 39, the LPIPS[9] score at D=0.1 is 0.0002, and the LPIPS[9] score at D=10.0 is 0.1734.



Fig. 3 Sample images generated by the Ours model trained on the CelebA[12] dataset. The FID[8] score is 26, the LPIPS[9] score at D=0.1 is 0.0002, and the LPIPS[9] score at D=10.0 is 0.1816.




Fig. 5 Sample images generated by the Ours model trained on the LSUN Bedroom[11] dataset. The FID[8] score is 55, the LPIPS[9] score at D=0.1 is 0.0007, and the LPIPS[9] score at D=14.0 is 0.3529.




Fig. 4 Sample images generated by the DCGAN[7] model trained on the LSUN Bedroom[11] dataset. The FID[8] score is 61, the LPIPS[9] score at D=0.1 is 0.0007, and the LPIPS[9] score at D=14.0 is 0.3444.

IV. 결 론

본 연구는 기존의 시행착오 중심 학습 패러다임에 대한 근본적 성찰에서 출발한다. 이론적 증명이나 명확한 원리 없이 반복적인 실험을 통해 불안정성을 해결하려는 기존 접근법의 한계를 극복하고자, 코사인 유사도 기반의 다양성 손실 함수를 제안한다. 사전 학습된 VGG16 네트워크에서 추출한 고수준 특징 간의 코사인 유사도를 최소화하는 손실 함수를 설계하고[10], 고차원 잠재 공간에서 무작위 샘플링된 벡터들의 분포 특성을 바탕으로 제안된 손실 함수가 잠재 공간의 의미적 연속성을 유지함을 수학적으로 증명한다.

본 연구의 핵심 기여는 단순한 정량적 지표 개선을 넘어서, 명확한 원리에 기반한 수학적으로 검증된 시각적 코사인 유사도가 일관되고 예측 가능한 성능 향상을 달성할 수 있음을 구체적으로 입증한다. 이러한 수학적 엄밀성을 바탕으로 한 구성 요소는 복잡한 적대적 생성 신경망 시스템에서도 안정적인 성능 개선을 보장한다. 이는 연구 패러다임을 경험 중심 개선에서 원리 중심 개선으로 전환하는 데 중요한 기여를 한다. 또한 잠재 공

간의 통계적 특성에 대한 수학적 분석을 통해 연속성과 다양성이라는 상충되는 목표 간의 조화로운 해결책을 제시한다.

제안된 방법론의 실용적 가치는, 기존 적대적 생성 신경망 구조를 변경하지 않고도 범용적으로 적용 가능하다는 점에 있다. 훈련 절차를 복잡하게 만들지 않으면서도 의미 있는 성능 향상을 달성하여, 제한된 자원 환경에서도 효과적으로 활용될 수 있다. 아울러, 대규모 생성 모델에도 무리 없이 확장 가능하여 다양한 실세계 응용 환경에서의 적용 가능성 또한 확보한다.

향후 연구에서는 다양한 적대적 생성 신경망 구조에 대한 일반화 성능을 체계적으로 검증하고, 데이터셋 특성에 따라 적응적으로 가중치를 조정하는 학습 기법을 개발할 예정이다. 나아가, 다중 스케일 특징 추출 및 자가 주의 메커니즘을 통합한 고차원 다양성 손실을 고안하여[4], 더욱 정교한 생성 모델 설계 원칙을 정립할 계획이다. 수학적 엄밀성과 실용성을 조화롭게 결합한 설계 철학을 바탕으로, 신뢰도 높은 생성 모델 훈련 방식을 제시하고, 향후 원리 기반의 안정적 적대적 생성 신경망 훈련 체계 확립에 기초를 제공할 것으로 기대된다.

ACKNOWLEDGEMENTS

This work was supported in part by the National Research Foundation of Korea (NRF) Grant funded by Korean Government [Ministry of Science and ICT (MSIT)] under Grant RS-2024-00338504

REFERENCES

- [1] I. J. Goodfellow, J. P. Abadie, M. Mirza, B. Xu, D. W. Farley, S. Ozair, A. Courville, and Y. Bengio, "Generative adversarial nets," *arXiv preprint arXiv: 1406.2661*, Jun. 2014. DOI: 10.48550/arXiv.1406.2661.
- [2] M. Arjovsky and L. Bottou, "Towards principled methods for training generative adversarial networks," *arXiv preprint arXiv: 1701.04862*, Jan. 2017. DOI: 10.48550/arXiv.1701.04862.
- [3] T. Karras, T. Aila, S. Laine, and J. Lehtinen, "Progressive Growing of GANs for Improved Quality, Stability, and Variation," *arXiv preprint arXiv: 1710.10196*, Oct. 2017. DOI: 10.48550/arXiv.1710.10196.
- [4] H. Zhang, I. Goodfellow, D. Metaxas, and A. Odena, "Self-attention generative adversarial networks," *arXiv preprint arXiv: 1805.08318*, May 2018. DOI: 10.48550/arXiv.1805.08318.
- [5] S. Zhao, Z. Liu, J. Lin, J. Zhu, and S. Han, "Differentiable augmentation for data-efficient GAN training," *arXiv preprint arXiv: 2006.10738*, Jun. 2020. DOI: 10.48550/arXiv.2006.10738.
- [6] T. Miyato, T. Kataoka, M. Koyama, and Y. Yoshida, "Spectral normalization for generative adversarial networks," *arXiv preprint arXiv: 1802.05957*, Feb. 2018. DOI: 10.48550/arXiv.1802.05957.
- [7] A. Radford, L. Metz, and S. Chintala, "Unsupervised representation learning with deep convolutional generative adversarial networks," *arXiv preprint arXiv: 1511.06434*, Nov. 2015. DOI: 10.48550/arXiv.1511.06434.
- [8] M. Heusel, H. Ramsauer, T. Unterthiner, B. Nessler, and S. Hochreiter, "GANs trained by a two time-scale update rule converge to a local Nash equilibrium," *arXiv preprint arXiv: 1706.08500*, Jun. 2017. DOI: 10.48550/arXiv.1706.08500.
- [9] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The unreasonable effectiveness of deep features as a perceptual metric," in *Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition*, Salt Lake City: USA, pp. 586-595, 2018. DOI: 10.1109/CVPR.2018.00068.
- [10] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," *arXiv preprint arXiv: 1409.1556*, Sep. 2014. DOI: 10.48550/arXiv.1409.1556.
- [11] F. Yu, A. Seff, Y. Zhang, S. Song, T. Funkhouser, and J. Xiao, "LSUN: Construction of a Large-scale Image Dataset using Deep Learning with Humans in the Loop," *arXiv preprint arXiv: 1506.03365*, Jun. 2015. DOI: 10.48550/arXiv.1506.03365.
- [12] Z. Liu, P. Luo, X. Wang, and X. Tang, "Deep learning face attributes in the wild," in *Proceedings of IEEE International Conference on Computer Vision (ICCV)*, Santiago: CL, pp. 3730-3738, 2015. DOI: 10.1109/ICCV.2015.425.
- [13] Q. Mao, H. Y. Lee, H. Y. Tseng, S. Ma, and M. H. Yang, "Mode Seeking Generative Adversarial Networks for Diverse Image Synthesis," *arXiv preprint arXiv: 1903.05628*, Mar. 2019. DOI: 10.48550/arXiv.1903.05628.

- [14] Z. Lin, A. Khetan, G. Fanti, and S. Oh, "PacGAN: The power of two samples in generative adversarial networks," *arXiv preprint arXiv: 1712.04086*, Dec. 2017. DOI: 10.48550/arXiv.1712.04086.
- [15] J. Johnson, A. Alahi, and L. F. Fei, "Perceptual losses for real-time style transfer and super-resolution," in *Proceedings of the 14th European Conference on Computer Vision (ECCV)*, Amsterdam: NL, pp. 694-711, 2016. DOI: 10.1007/978-3-319-46475-6_43.
- [16] T. Karras, S. Laine, and T. Aila, "A style-based generator architecture for generative adversarial networks," in *Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Long Beach: USA, pp. 4396-4405, 2019. DOI: 10.1109/CVPR.2019.00453.
- [17] Y. Gong, M. Zhong, Y. Ji, M. Xie, and X. Ma, "Distribution constraining for combating mode collapse in generative adversarial networks," *Journal of Electronic Imaging*, vol. 32, no. 4, pp. 043029, Aug. 2023. DOI: 10.1117/1.JEI.32.4.043029.
- [18] H. Liu, B. Li, H. Wu, H. Liang, Y. Huang, Y. Li, B. Ghanem, and Y. Zheng, "Combating mode collapse via offline manifold entropy estimation," *AAAI Technical Track on Machine Learning II*, vol. 37, no. 7, pp. 8834-8842, Jun. 2023. DOI: 10.1609/aaai.v37i7.26062.
- [19] Y. Luo and Z. Yang, "DynGAN: Solving mode collapse in GANs with dynamic clustering," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 46, no. 8, pp. 5493-5503, Aug. 2024. DOI: 10.1109/TPAMI.2024.3367532.
- [20] O. Goni, H. S. Arka, M. Halder, M. M. A. Shibly, and S. Shatabda, "HingeRLC-GAN: Combatting Mode Collapse with Hinge Loss and RLC Regularization," in *Proceedings of the 27th International Conference*, Kolkata: IN, pp. 370-385, 2024. DOI: 10.1007/978-3-031-78389-0_25.
- [21] Y. Wei, J. Zhang, and L. Zhong, "RIS-GAN: Self-Supervised GANs via Recovering Initial State of Subimages," *Pattern Recognition Letters*, vol. 165, pp. 114-121, Jan. 2023. DOI: 10.1016/j.patrec.2022.12.005.
- [22] L. Hou, Q. Cao, Y. Yuan, S. Zhao, C. Ma, S. Pan, P. Wan, Z. Wang, H. Shen, and X. Cheng, "Augmentation-aware self-supervision for data-efficient GAN training," in *Proceedings of Advances in Neural Information Processing Systems*, New Orleans: USA, pp. 31601-31620, 2023. DOI: 10.5555/3666122.3667494.
- [23] Q. Zhou, J. Zhang, G. Han, Z. Ruan, and Y. Wei, "Enhanced self-supervised GANs with blend ratio classification," *Multimedia Tools and Applications*, vol. 81, no. 6, pp. 7651-7667, Mar. 2022. DOI: 10.1007/s11042-022-12056-2.



서상원(Sang-Won Seo)

국립한국교통대학교 컴퓨터공학과 학사

※ 관심분야: 적대적 생성 신경망, 인공지능, 영상처리



박현철(Hyun-Cheol Park)

2024년~현재 국립한국교통대학교 컴퓨터공학과 조교수

2023년 국가수리과학연구소 박사후연구원

2022년 가천대학교 IT융합공학 공학박사

※ 관심분야: 컴퓨터비전, 인공지능, 의료영상처리